


Modelos Ocultos de Markov


Jorge Luis Guevara Díaz
Universidad Nacional de Trujillo
Escuela de Informática





Introducción

- Son modelos muy utilizados en diversas áreas, la razón de esto es que poseen una rica estructura matemática y es esto lo que forma a base teórica para poder aplicarlos en muchas áreas, funcionando muy bien en la práctica





Introducción

- ¿Cómo caracterizar señales del mundo real en términos de modelos?
 - Por ejemplo:
 - Mejorar una señal ruidosa, para esto se debe establecer un modelo de que es una señal no ruidosa
 - Como encontrar un buen modelo?
 - Que tipo de modelo usar?



Introducción

- Modelos de señal determinísticos
 - Propiedades específicas de la señal. Ejemplo: la señal es una onda seno, amplitudes, frecuencias, etc
- Modelos de señal estocásticos
 - Modelos estadísticos de la señal, se busca solamente caracterizar las propiedades estadísticas de la señal. Ejemplo: Procesos Gaussianos, procesos Poisson, Procesos de Markov, Procesos Ocultos de Markov, etc



Introducción

- Para RAH necesitaremos ambos tanto los modelos determinísticos como los modelos estocásticos
- A continuación estudiaremos un modelo estocástico los HMM (Hidden Markov Models) Modelos Ocultos de Markov



Introducción

- Estos modelos fueron introducidos en los años 1960 por Baum, y fue utilizado para aplicaciones de procesamiento de señales de habla por Baker y Jelinek a mediados de 1970



Introducción

- Sea $\mathbf{X} = X_1, X_2, \dots, X_n$ una secuencia de variables aleatorias de un alfabeto discreto $\mathcal{O} = \{o_1, o_2, \dots, o_M\}$
Según la regla de Bayes tenemos

$$P(X_1, X_2, \dots, X_n) = P(X_1) \prod_{i=2}^n P(X_i | X_1^{i-1})$$

donde

$$X_1^{i-1} = X_1, X_2, \dots, X_{i-1}$$

Se dice que las variables aleatorias \mathbf{X} son cadenas de Markov de primer orden si

$$P(X_i | X_1^{i-1}) = P(X_i | X_{i-1})$$



Introducción

- Entonces

$$P(X_1, X_2, \dots, X_n) = P(X_1) \prod_{i=2}^n P(X_i | X_1^{i-1})$$

- Viene a ser

$$P(X_1, X_2, \dots, X_n) = P(X_1) \prod_{i=2}^n P(X_i | X_{i-1})$$

Procesos Discretos de Markov




- Consideremos un sistema que puede ser descrito en cualquier instante de tiempo, empezando en cualquiera de sus N estados

Estados espaciados
regularmente en el tiempo

S_1, S_2, \dots, S_N

Cadena de Markov de $N=5$ estados



Procesos Discretos de Markov



- Cada estado tiene asociada una probabilidad
- Existen instantes de tiempo asociados a cada instante $t = 1, 2, \dots$
- El estado actual en el tiempo t será denotada mediante q_t
- Existen probabilidades de transición entre estados a_{ij}

Procesos Discretos de Markov



- Una descripción probabilística completa del sistema requiere la especificación del actual estado en el tiempo t y todos los estados predecesores
- Las cadenas de Markov de primer orden truncan esta descripción probabilística, justo en el estado predecesor

$$\begin{aligned} P[q_t = S_j | q_{t-1} = S_i, q_{t-2} = S_k, \dots] \\ = P[q_t = S_j | q_{t-1} = S_i]. \end{aligned}$$

Procesos Discretos de Markov



- Las probabilidades de transición de estados a_{ij} tienen entonces la siguiente forma

$$a_{ij} = P[q_t = S_j | q_{t-1} = S_i], \quad 1 \leq i, j \leq N$$

Con $a_{ij} \geq 0$

$$\sum_{j=1}^N a_{ij} = 1$$

Modelo observable de Markov



Procesos Discretos de Markov

- En conclusión una cadena de Markov con N estados donde el estado en el tiempo t puede ser descrito como q_t puede ser descrita como
 1. Un conjunto finito de estados $Q = \{q_1, q_2, \dots, q_n\}$
 2. Una distribución de probabilidad inicial en todos los estados

$$\pi_i = P[q_1 = S_i], \quad 1 \leq i \leq N \quad \sum_{j=1}^N \pi_j = 1$$


3. Una matriz de transición de estados

$$a_{ij} = P[q_t = S_j | q_{t-1} = S_i], \quad 1 \leq i, j \leq N$$

con

$$\sum_{j=1}^N a_{ij} = 1 \quad 1 \leq i \leq N \quad a_{ij} \geq 0$$

Procesos Discretos de Markov



- Teniendo esto en mente se puede decir que un modelo de cadena de Markov incorpora un monto mínimo de memoria



Ejemplo

- Modelo de 3 estados de Markov del Tiempo
 - Estado 1 lluvioso
 - Estado 2 nublado
 - Estado 3 soleado

Matriz de transición de probabilidades

$$A = \{a_{ij}\} = \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix}.$$



Ejemplo

- Dado que el tiempo en el día $t = 1$ es soleado (estado 3), ¿Cuál es la probabilidad de acuerdo al modelo que el tiempo de los siguientes 7 días sea **soleado – soleado – lluvioso – lluvioso – soleado – nublado – soleado** ?

- Es decir, dada una secuencia de Observaciones

$$O = \{ S_3, S_3, S_1, S_1, S_3, S_2, S_3 \} \text{ para}$$

$$t = \{1...8\}$$


Determinar la probabilidad de O dado el *modelo*



Ejemplo


$$\begin{aligned} P(O|\text{Model}) &= P[S_3, S_3, S_3, S_1, S_1, S_3, S_2, S_3|\text{Model}] \\ &= P[S_3] \cdot P[S_3|S_3] \cdot P[S_3|S_3] \cdot P[S_1|S_3] \\ &\quad \cdot P[S_1|S_1] \cdot P[S_3|S_1] \cdot P[S_2|S_3] \cdot P[S_3|S_2] \\ &= \pi_3 \cdot a_{33} \cdot a_{33} \cdot a_{31} \cdot a_{11} \cdot a_{13} \cdot a_{32} \cdot a_{23} \\ &= 1 \cdot (0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2) \\ &= 1.536 \times 10^{-4} \end{aligned}$$

Procesos Discretos de Markov



- Dado el modelo en un estado conocido,
¿Cuál es la probabilidad de que permanezca
en el mismo estado exactamente d días?

Procesos Discretos de Markov



- Probabilidad de la secuencia de Observación

$$O = \{S_{i_1}, S_{i_2}, S_{i_3}, \dots, S_{i_d}, S_{i_{d+1}} \neq S_{i_d}\},$$

- Dado el modelo

$$P(O|\text{Model}, q_1 = S_i) = (a_{ii})^{d-1}(1 - a_{ii}) = p_i(d).$$

- Donde $p_i(d)$ es la función de densidad de probabilidad discreta de duración d en el estado i



Procesos Discretos de Markov

- El número esperado de observaciones en un estado basado en $p_i(d)$ es el siguiente:

$$\begin{aligned}\bar{d}_i &= \sum_{d=1}^{\infty} d p_i(d) \\ &= \sum_{d=1}^{\infty} d (a_{ii})^{d-1} (1 - a_{ii}) = \frac{1}{1 - a_{ii}}.\end{aligned}$$

¿Cuál es el número esperado de días consecutivos soleados, nublados, lluviosos?

$$1/(0.2) = 5,$$

$$2.5$$

$$1.67$$




Otro Ejemplo

- ¿Cuál es la probabilidad de up-up-up-up-up?

$$A = \{a_{ij}\} = \begin{bmatrix} 0.6 & 0.2 & 0.2 \\ 0.5 & 0.3 & 0.2 \\ 0.4 & 0.1 & 0.5 \end{bmatrix}$$

$$\pi = (\pi_i)^t = \begin{pmatrix} 0.5 \\ 0.2 \\ 0.3 \end{pmatrix}$$





Modelos Ocultos de Markov

- Considere el siguiente escenario:
Una persona hace experimentos con monedas, y solamente nos dice el resultado de sus experimentos. Es decir una secuencia ***oculta*** es realizada, por ejemplo

Una secuencia oculta de caras y sellos toma lugar

$$\mathbf{O} = O_1 O_2 O_3 \cdots O_T$$

$$= \mathcal{K} \mathcal{K} \mathcal{J} \mathcal{J} \mathcal{J} \mathcal{K} \mathcal{J} \mathcal{J} \mathcal{K} \cdots \mathcal{K}$$

\mathcal{K} cara \mathcal{J} sello




Modelos Ocultos de Markov

- ¿Cómo construir un HMM que explique la secuencia observada de caras y sellos?
 - Problemas:
 1. Que estados corresponderan a caras y sellos?
 2. Cuantos estados deberá tener el modelo?
 3. Cual es el mejor modelo?



Modelos Ocultos de Markov

Si tenemos una sola moneda el modelo podría tener dos estados, cada estado corresponderá a cada lado de la moneda, se trata de un modelo observable, solo se necesita saber el valor de un bias, para completar la especificación




O = HHTTHTHTTH...
S = 11221211221...



Modelos Ocultos de Markov

- Otra forma, dos estados, cada estado corresponde a dos diferentes monedas con bias, cada estado es caracterizado por la distribucion de probabilidad de cabezas y colas, las transiciones dependen de una matriz de transicion de estados




O = H H T T H T H H T T H ...
S = 2 1 1 2 2 2 1 2 2 1 2 ...



Modelos Ocultos de Markov

- Otra manera



O = H H T T H T H H T T H ...
S = 3 1 2 3 3 1 1 2 3 1 3 ...

	STATE		
	1	2	3
P(H)	P_1	P_2	P_3
P(T)	$1-P_1$	$1-P_2$	$1-P_3$



Modelos Ocultos de Markov

- Se usan tres monedas con bias y se escogen de entre las tres, basado en algún evento de probabilidad
- ¿Cuál es el mejor modelo para las observaciones actuales?



Modelos Ocultos de Markov

- Elementos

1. **N** número de estados en el modelo
 1. Estados individuales $\mathbf{S} = \{S_1 \dots S_N\}$
 2. Estado en el tiempo $t = q_t$
2. **M** numero de distintos símbolos de observación por estado, corresponde con la salida física del sistema modelado, por ejemplo para los experimentos de las monedas será cara o sello
 1. Los símbolos individuales se denotarán como
$$\mathbf{V} = \{v_1 \dots v_M\}$$



Modelos Ocultos de Markov

3. La distribución de probabilidad de transiciones de estados $\mathbf{A} = \{\mathbf{a}_{ij}\}$ donde

$$a_{ij} = P[q_{t+1} = S_j | q_t = S_i], \quad 1 \leq i, j \leq N$$

4. La distribución de probabilidad de las observaciones de los símbolos en el estado

$$j, \mathbf{B} = \{b_j(k)\}$$

donde

$$b_j(k) = P[v_k \text{ at } t | q_t = S_j], \quad 1 \leq j \leq N$$

$$1 \leq k \leq M.$$



Modelos Ocultos de Markov

5. La distribución inicial de estado $\pi = \{\pi_i\}$
donde

$$\pi_i = P[q_1 = S_i], \quad 1 \leq i \leq N.$$

Dado apropiados valores de **N, M, A, B** y **π** el HMM puede ser usado para generar para obtener la secuencia de observaciones

$$O = O_1 O_2 \cdots O_T$$

Donde cada observación **O_t** es uno de los símbolos de **V** y **T** es el número de observaciones en la secuencia



Modelos Ocultos de Markov

- Uso del HMM como generador (algoritmo)
 1. Escoger un estado inicial, $q_1 = S_i$ de acuerdo a la distribución inicial de estado $\boldsymbol{\pi}$
 2. $t \leftarrow 1$
 3. Escoger $O_t = v_k$ de acuerdo a la distribución de probabilidad de símbolos en el estado \mathbf{S}_i , $b_i(k)$
 4. Transitar al nuevo estado $q_{t+1} = S_j$ conforme a la distribución de probabilidad de transiciones de estados para el estado \mathbf{S}_i , a_{ij}

Modelos Ocultos de Markov



5. $t \leftarrow t + 1$, retornar al paso 3 si $t < T$, de otra manera terminar

El algoritmo anterior como un HMM puede ser usado como generador de observaciones o como un modelo, dada una secuencia de observaciones como fue generada por un HMM



Modelos Ocultos de Markov

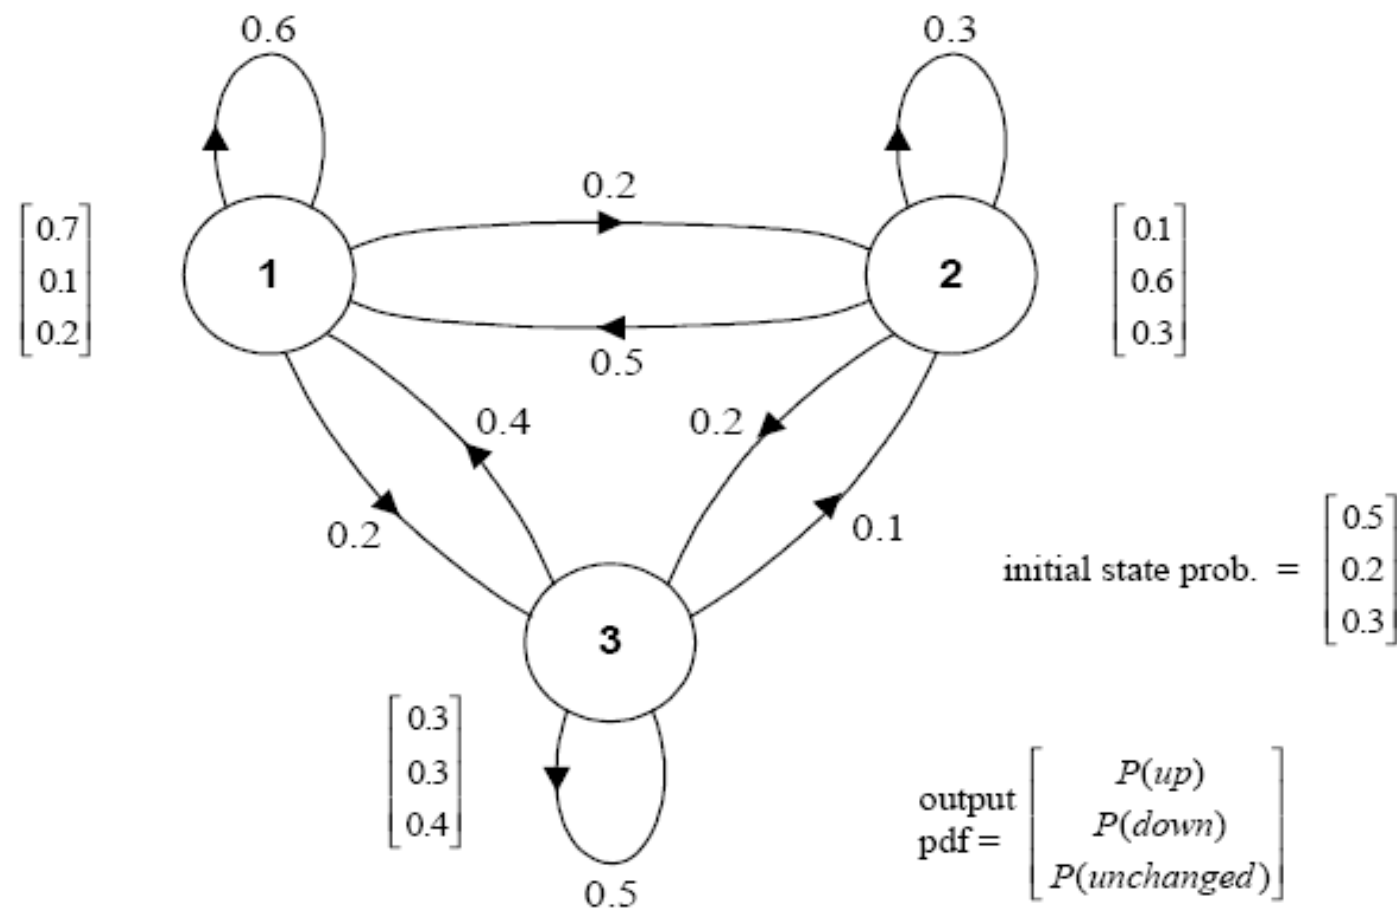
- Los HMM, para ser especificados necesitan los parámetros **N** y **M** , también necesitan la especificación de los símbolos de observación y de las tres distribuciones de probabilidad, **A** , **B** y **π** , Para denotar todo esto se utilizará la siguiente notación

$$\lambda = (A, B, \pi)$$



Modelos Ocultos de Markov

- Ejemplo





Modelos Ocultos de Markov

- Los tres problemas básicos

Se deben resolver tres problemas básicos para que el modelo sea útil a aplicaciones reales

 1. Problema 1 (evaluación)
 2. Problema 2 (decodificación)
 3. Problema 3 (aprendizaje)



Modelos Ocultos de Markov

1. **Problema 1 (evaluación)** Dada una secuencia de observación $\mathbf{O} = \mathbf{O}_1 \dots \mathbf{O}_T$ y un modelo $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, como calcular eficientemente $P(\mathbf{O}/\lambda)$, la probabilidad de la observación dado el modelo?
2. **Problema 2 (decodificación)** Dada una secuencia de observación $\mathbf{O} = \mathbf{O}_1 \dots \mathbf{O}_T$ y un modelo λ , como escoger una correspondiente secuencia de estados $\mathbf{Q} = \mathbf{q}_1 \dots \mathbf{q}_T$ que sea óptima, es decir que mejor explique la observación
3. **Problema 3 (aprendizaje-entrenamiento)** Como ajustar los parámetros del modelo $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ para maximizar $P(\mathbf{O}/\lambda)$?



Modelos Ocultos de Markov

- Ejemplo en RAH
 - Por cada palabra construir un HMM de N estados
 - La señal de habla de determinada palabra es una secuencia de vectores espectrales (codificados),
 - Se puede establecer un codificador espectral con M vectores espectrales unicos, siendo cada observacion el índice de este codificador más cercano a la señal



Modelos Ocultos de Markov

- Para cada palabra del vocabulario realizar un entrenamiento para construir un modelo de palabra, esto es hecho solucionando el problema numero 3
- Para saber cual es la secuencia de estados y hacer un refinamiento posterior, se solucionará el problema numero 2
- El reconocimiento de una palabra se hará solucionando el problema 1

Solucion a los tres básicos problemas de los HMM



- Solución al problema 1
 - Calcular la probabilidad de la secuencia $\mathbf{O} = O_1 \dots O_T$ dado el modelo $\lambda = (A, B, \pi)$, es decir $P(\mathbf{O} / \lambda)$
 - La manera mas ingenua sería ennumerar toda la posible secuencia de estados de longitud T , por ejemplo si consideramos una secuencia fija de estados

$$Q = q_1 q_2 \dots q_T$$



Solucion problema 1

- La probabilidad de la secuencia de observacion para la secuencia de estados anterior es

$$P(O|Q, \lambda) = \prod_{t=1}^T P(O_t|q_t, \lambda)$$

$$P(O|Q, \lambda) = b_{q_1}(O_1) \cdot b_{q_2}(O_2) \cdot \dots \cdot b_{q_T}(O_T)$$

- La probabilidad de la secuencia de estados dado el modelo es

$$P(Q|\lambda) = \pi_{q_1} a_{q_1 q_2} a_{q_2 q_3} \cdot \dots \cdot a_{q_{T-1} q_T}$$



Solucion problema 1

- La probabilidad de que **O** y **Q** ocurran simultaneamente :

$$P(O, Q|\lambda) = P(O|Q, \lambda) P(Q, \lambda)$$

- La probabilidad de **O** dado el modelo $P(O/\lambda)$ es la sumatoria de todas las posibles combinaciones e secuencias de estados **q**

$$\begin{aligned} P(O|\lambda) &= \sum_{\text{all } Q} P(O|Q, \lambda) P(Q|\lambda) \\ &= \sum_{q_1, q_2, \dots, q_T} \pi_{q_1} b_{q_1}(O_1) a_{q_1 q_2} b_{q_2}(O_2) \\ &\quad \dots a_{q_{T-1} q_T} b_{q_T}(Q_T). \end{aligned}$$



Solucion problema 1

- La ecuación anterior se interpreta como sigue:
 1. En el tiempo $t=1$, estamos en el estado q_1 con probabilidad π_{q_1} y generamos el símbolo O_1 , con probabilidad $b_{q_1}(O_1)$,
 2. En el tiempo $t=t+1$, hacemos una transición al estado q_2 , con probabilidad $a_{q_1q_2}$, y generamos el símbolo O_2 con probabilidad $b_{q_2}(O_2)$
 3. ...
 4. Hasta el tiempo T
 5. Se cambia la secuencia de estados



Solucion problema 1

Complejidad $2T \cdot N^T$ cálculos, pues existen N^T posibles secuencias de estados y cada secuencia de estados requiere $2T$ calculos

No es práctico pues para pequeños valores de N y T por ejemplo $N = 5$ y $T = 100$ se necesitarán aproximadamente $2 \cdot 100 \cdot 5^{100} \approx 10^{72}$ operaciones de cálculo



Solucion problema 1

- Afortunadamente existe un algoritmo, que realiza lo mismo en menos operaciones, este es el algoritmo ***forward-backward***



Solucion problema 1

- Algoritmo ***forward-backward***
considerar

$$\alpha_t(i) = P(O_1 O_2 \cdots O_t, q_t = S_i | \lambda)$$

como la probabilidad de la secuencia de observacion parcial $O_1 \dots O_t$ hasta el tiempo t y el estado S_i en el tiempo t dado el modelo λ .



Algoritmo *forward-backward*

1. Inicialización

$$\alpha_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq N$$


2. Inducción

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1$$
$$1 \leq j \leq N.$$


1. Terminación

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

Algoritmo *forward-backward*




Algoritmo *forward-backward*






Algoritmo *forward*-backward

*HIDDEN MARKOV MODELS



Algoritmo *forward-backward*





Algoritmo *forward-backward*

- Complejidad N^2T operaciones de cálculo, para $N = 5$ y $T = 100$ se necesitarán solamente 3000 cálculos frente a los 10^{72} con un cálculo directo

Aproximadamente menos 69 ordenes de magnitud !!!



Algoritmo *forward-backward*

- De similar manera podemos considerar

$$\beta_t(i) = P(O_{t+1} O_{t+2} \cdots O_T | q_t = S_i, \lambda)$$

la probabilidad de la secuencia de observaciones parciales de ***t+1*** hasta ***T*** dado el estado ***S_i*** en el tiempo ***t*** y el modelo ***λ***



Algoritmo *forward-backward*

1. Inicialización

$$\beta_T(i) = 1, \quad 1 \leq i \leq N.$$

2. Inducción


$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j),$$

$$t = T - 1, T - 2, \dots, 1, 1 \leq i \leq N.$$


La parte ***Backward*** del algoritmo se usará para solucionar el problema 2 más no el problema 1



Algoritmo *forward-backward*



Algoritmo *forward-backward*




Ejemplo



$$a_{ij} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0.2 & 0.3 & 0.1 & 0.4 \\ 0.2 & 0.5 & 0.2 & 0.1 \\ 0.8 & 0.1 & 0.0 & 0.1 \end{pmatrix}$$

$$b_{jk} = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 0.3 & 0.4 & 0.1 & 0.2 \\ 0 & 0.1 & 0.1 & 0.7 & 0.1 \\ 0 & 0.5 & 0.2 & 0.1 & 0.2 \end{pmatrix}$$





Ejemplo

- ¿Cuál es la probabilidad de generar la secuencia $V^5 = \{v_3, v_1, v_3, v_2, v_0\}$?

